

Team. CleanRoad

음주운전 사고 양형 불균형 분석

Analysis of Sentencing Imbalances in Drunk Driving Accidents

판결문 TEXT-MINING 기반 요인별 형량 예측 모델

목차

Phase1. Preview

- 프로젝트 개요
- 기초 분석 결과
- 데이터 전처리

Phase 2. ML

- 모델 비교
- 성능 개선
- 성능 확인

Phase 3. Result

- 도출된 인사이트
- 한계점
- 향후 연구 계획

Phase 1. Preview

주제 선정 이유 및 프로젝트 설명

주제 선정 이유

사회 > 법원·검찰

같은 음주운전을 해도...강남서 걸리면 처벌이 더 낮다고?

양형 불균형에 대한 의구심

판결문 텍스트마이닝 기반
양형 불균형 분석 및 영향 요소 파악



LBOX

최근 5년 12개 지역 판결문 크롤링
최종 6337개 데이터

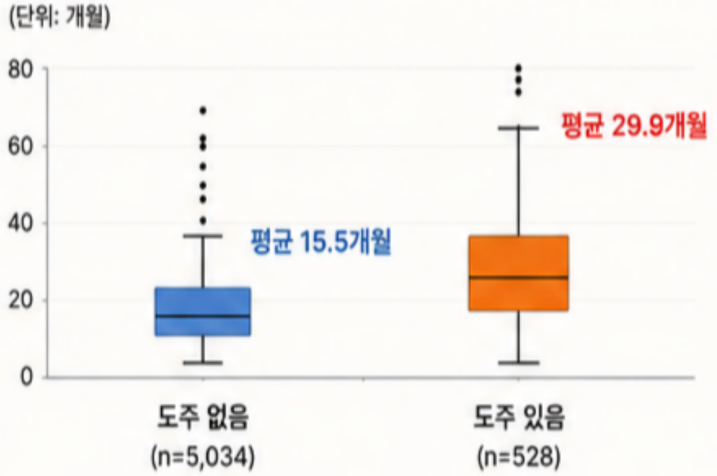
박홍주, "같은 음주운전을 해도...강남서 걸리면 처벌이 더 낮다고?", 매일경제, 2023.03.29, https://www.mk.co.kr/news/society/10698926

Phase 1.1 Feedback Complement

종속 변수 기준 EDA

01 도주 여부별 선고형량 분포

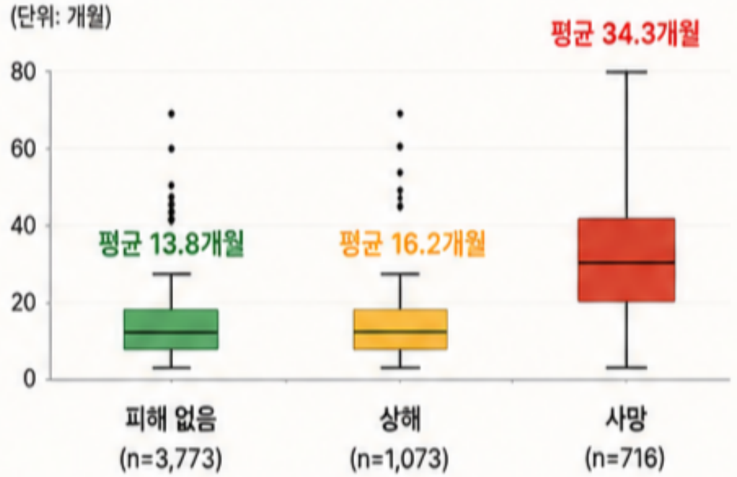
도주 사건은 비도주 사건보다
평균 선고형량이 약 1.9배 높음



도주 있음 평균 29.9개월 > 도주 없음 평균 15.5개월

02 피해 결과(유형)별 선고형량 분포

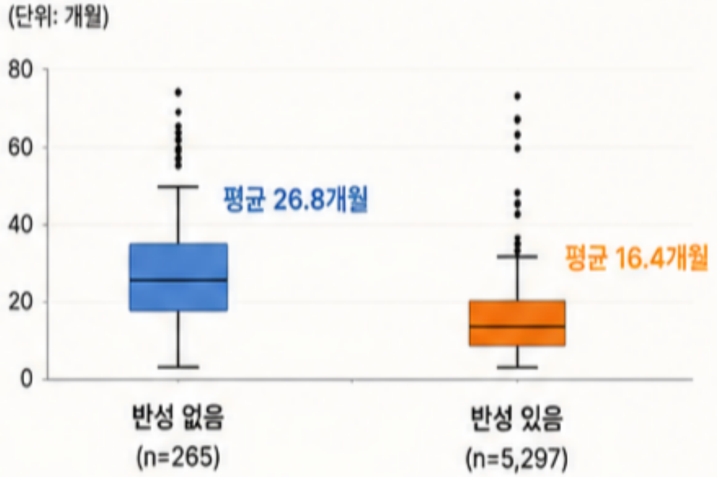
피해 없음 < 상해 < 사망 순으로
평균 선고형량이 단계적으로 증가



피해 없음 13.8개월 < 상해 16.2개월 < 사망 34.3개월

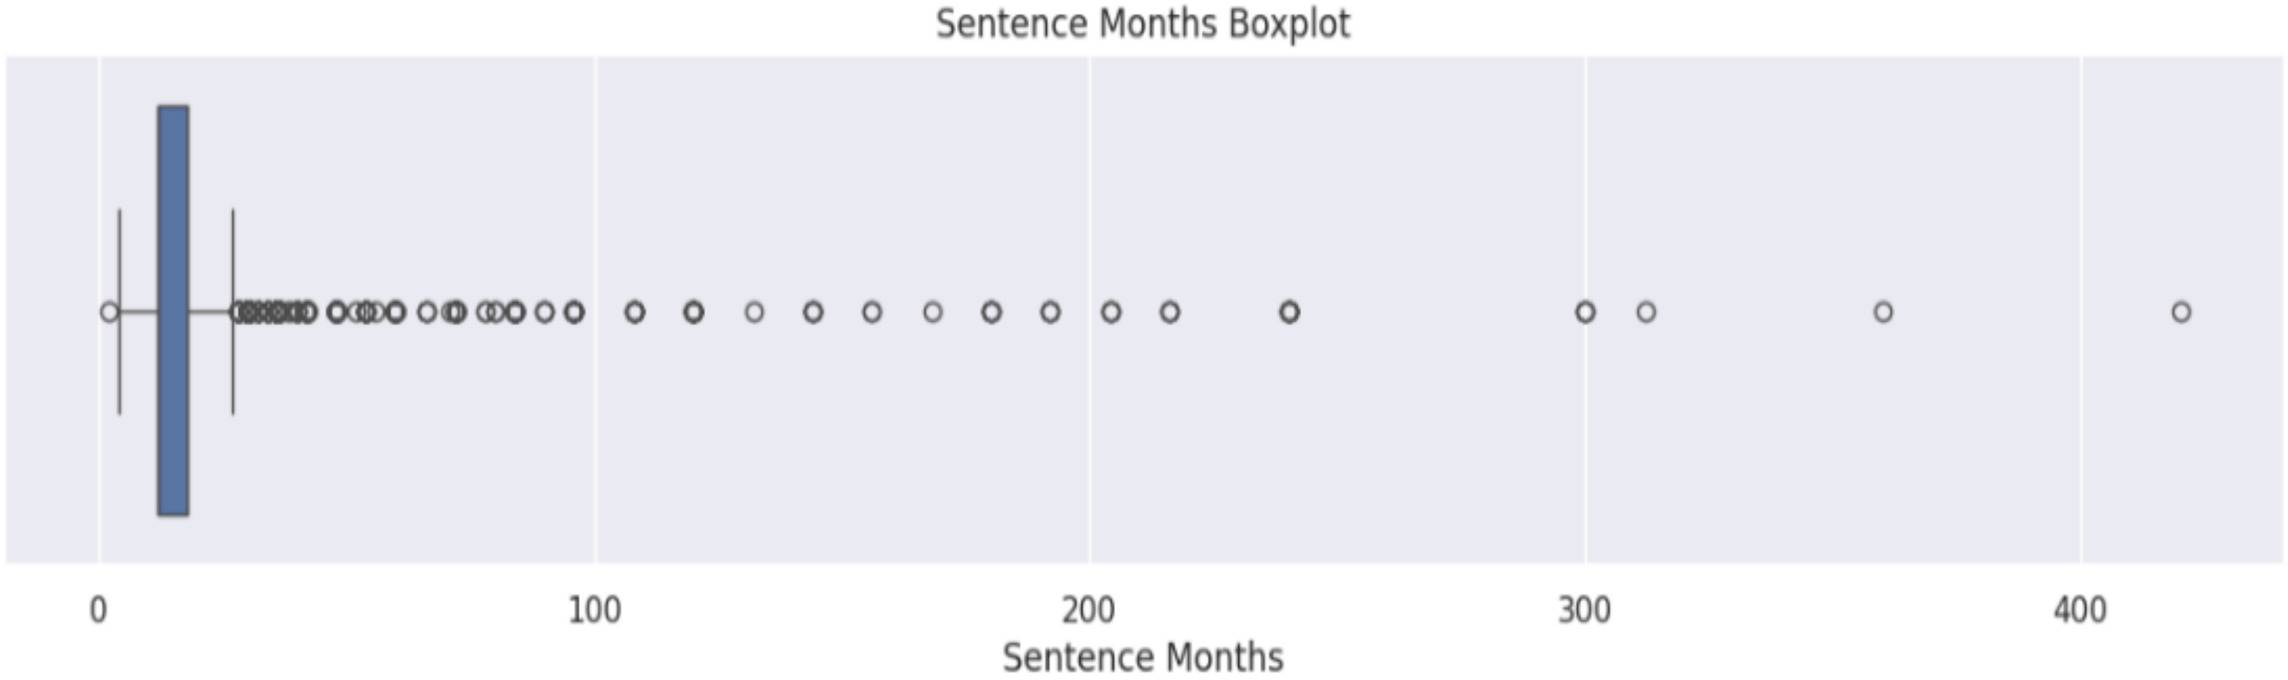
03 반성 여부별 선고형량 분포

반성 표평이 있는 사건은
평균 선고형량이 약 10개월 이상 낮게 나타남



반성 없음 평균 26.8개월 > 반성 있음 평균 16.4개월

타겟 변수 분포



형량은 대부분 12~18개월에 집중되어 있으나 극단적 장기형 이상치가 존재

2차 피드백 기반 보완

01	결측치·BAC 처리 기준 재정리	fine_amount, driving_distance_km 등 결측 과다 피처는 모델 입력 제외 BAC는 max 값 임의 대체 철회 → 결측 처리 기준으로 재정리
02	IQR 이상치 탐지	Boxplot 기준 27개월 초과 장기형 사건 확인 → 사망·도주 등 중대 사건이 반영된 유효 데이터로 판단 → 제거하지 않고 모델링 및 결과 해석에 활용
03	타깃 변수 정리: 벌금형 환산	EDA 과정에서 벌금형을 0개월로 두면 타깃값이 왜곡되는 문제 확인 → sentence_months=1로 학습
04	Scaling 기준 정리	Random Forest: 트리 기반 모델이므로 스케일링 영향 작음 SVM: 거리·마진 기반 모델이므로 StandardScaler 적용

2차 피드백 기반 보완

Feature 선정 근거

구분	피처	도메인 근거
가중요인	death	사망 결과 → 피해 결과의 중대성
	fleeing	사고 후 도주 → 사건 중대성 및 가중 요소 반영
	injury	상해 발생 → 피해 결과의 중대성
	n_prior	전과 횟수 → 재범성 반영
	same_type_prior	동종·음주 전과 → 재범 위험성
감경요인	settlement	피해자 합의 → 피해 회복 노력
	remorse	반성 표명 → 개선 의지
	insurance	보험 가입 → 피해 보상 가능성
기본·통제	bac	혈중알코올농도 → 음주 정도 수치화
	court_region	법원 소재지 → 지역별 차이 통제
	year	선고 연도 → 시계열 변화 통제
제외	fine_amount	결측 5,890건 (93%) → 모델 입력 제외
	driving_distance_km	결측 3,278건 (52%) → 모델 입력 제외

Phase 2. ML

알고리즘 선택



판결문 데이터

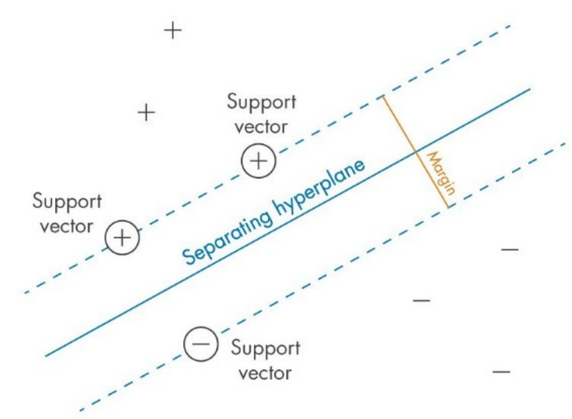
수치형 + 범주형 데이터

binary data 많음

특정 값에 과도하게 몰린 데이터

다양한 변수가 형량에
복합적으로 영향을 미침

SVM



$$\hat{y} = \mathbf{w}^T\mathbf{x} + b$$

스케일링 후 모든 변수를
동등하게 반영

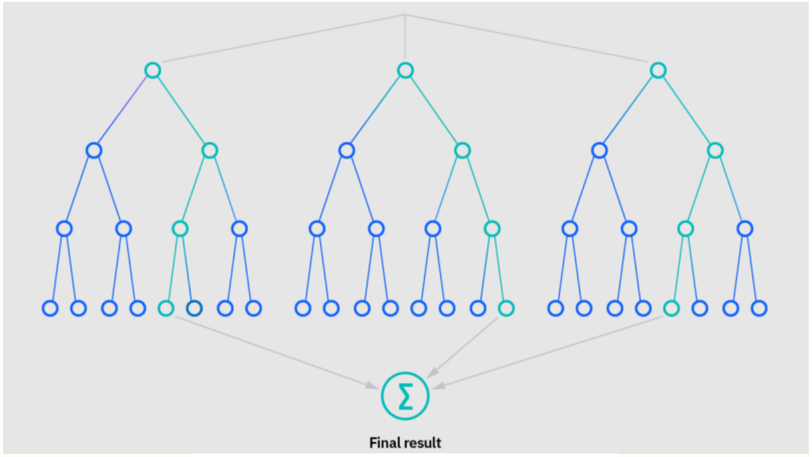
희소 패턴도 서포트 벡터로 포착

RBF 커널로 비선형 관계 변환

데이터와의 적합성을 고려해 이론적으로 SVM이 적합할 것이라고 예상하였으나,
실제 실험을 통해 다른 모델과 비교

비교 알고리즘 설명

Random Forest



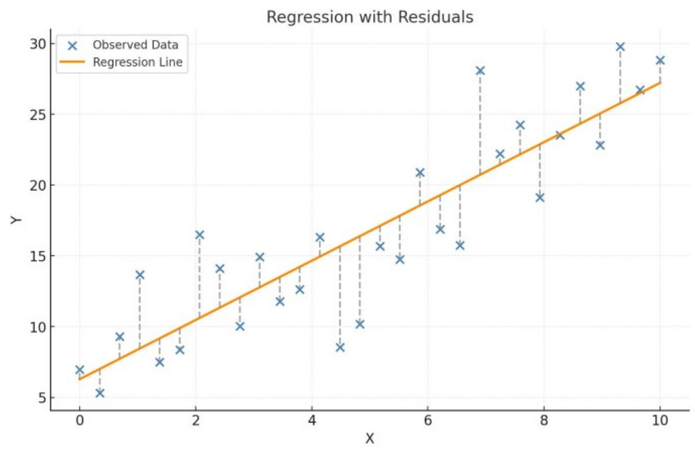
$$\hat{Y} = \frac{1}{T}\sum_{t=1}^{T} h_t(x)$$

다수의 결정 트리를 독립적으로 학습
→ 평균을 예측값으로 사용

연속형 + 범주형 + 이진 변수가 혼재하는 데이터에 강함

Feature Importance 해석이 용이

Linear Regression



$$\hat{y} = w_0 + w_1 x_1 + w_2 x_2 + \ldots + w_n x_n$$

각 입력 변수가 타깃에 미치는 영향을 독립적·선형적으로 더해 예측

모든 변수의 스케일이 일정하게 유지되고 관계가 단순할 때 잘 작동
변수 간 상호작용이나 비선형 관계를 자동으로 포착하지 못함

성능 하한선 역할

알고리즘별 주요 파라미터

SVM

Parameter	역할	후보 값	값
kernel	데이터 변환 방식	rbf	rbf
C	오차 허용 정도 조절	1, 5, 10, 30, 50, 100, 200	1
epsilon	허용 오차 범위	0.01, 0.05, 0.1, 0.2, 0.5	0.01
gamma	RBF kernel 영향 범위	"scale", "auto", 0.01, 0.05, 0.1	auto

알고리즘별 주요 파라미터

Random Forest

Parameter	역할	값
n_estimators	생성할 트리 개수	300
max_depth	트리 최대 깊이	20
min_samples_split	노드 분할 최소 샘플 수	2
min_samples_leaf	리프 노드 최소 샘플 수	1
max_features	분할 시 사용할 feature 수	0.5

Linear Regression

Parameter	역할	값
fit_intercept	절편 β_0를 계산할지 여부	True
positive	회귀계수를 양수로만 제한할지 여부	False

성능지표 설계

MAE : 실제 형량과 예측 형량의 평균 절대 오차 $MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$

RMSE : 큰 오차에 더 민감한 평균 제곱근 오차 $RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$

R^2 : 모델이 형량 변동을 설명하는 비율 $R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$

Accuracy with Tolerance: 실제값과 예측값의 차이가 특정 허용 범위(±k) 이내인 경우를 정답으로 간주하여 계산한 정확도 지표. 형량 오차 허용 범위를 반영

```
"Tol_3": make_scorer(lambda y_true, y_pred: np.mean(np.abs(y_true - y_pred) <= 3)),
"Tol_6": make_scorer(lambda y_true, y_pred: np.mean(np.abs(y_true - y_pred) <= 6)),
```

성능지표 설계

번호	실제 형량 (개월)	예측 형량 (개월)	오차
1	18	12.25	5.75
2	12	10.27	1.73
3	18	14.71	3.29
4	18	16.87	1.13
5	12	8.69	3.31

MAE: 3.04개월 $(5.75 + 1.73 + 3.29 + 1.13 + 3.31) \div 5$

→ 평균적으로 실제 형량과 약 3개월 차이로 예측

RMSE: 3.44개월 $\sqrt{((5.75^2 + 1.73^2 + 3.29^2 + 1.13^2 + 3.31^2) \div 5)}$

→ 번호 1처럼 극단적 오차 발생 여부를 파악하는 데 활용

R^2: 0.63 $1 - (59.11 \div 158.8)$

→ 모델이 실제 형량 변동의 63%를 설명

Accuracy (±3): 40%

→ 예측값이 실제 형량과 3개월 이내 차이면 맞힌 것으로 간주

Accuracy (±6): 60%

→ 예측값이 실제 형량과 6개월 이내 차이면 맞힌 것으로 간주

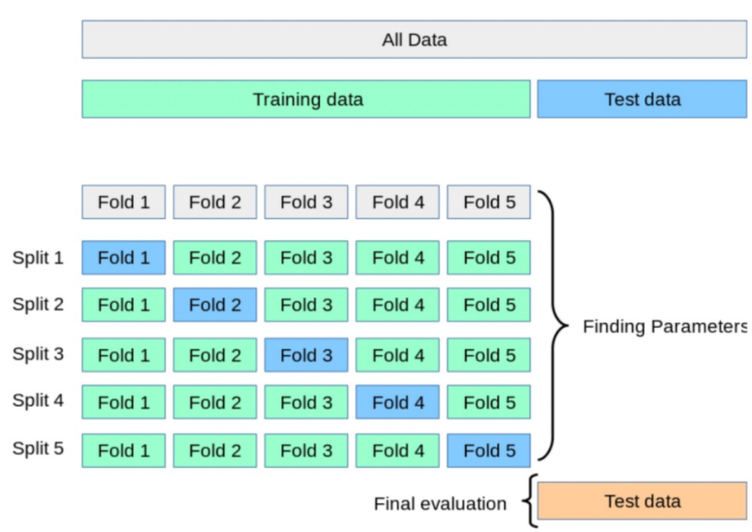
GridSearchCV & 5-Fold Cross Validation

GridSearchCV

여러 하이퍼파라미터 후보 조합을 자동으로 실험하고,
가장 성능이 좋은 조합을 선택하는 방식

5-Fold Cross Validation

데이터를 5개의 Fold로 나누어 4개는 학습, 1개는 검증에
사용하며 이를 5번 반복하여 모델의 일반화 성능을
평가하는 방법



성능 확인

	MAE	RMSE	R^2	Accuracy Toler : 3	Accuracy Toler : 6
Random Forest	4.916	10.805	0.359	48.05%	77.80%
SVM	4.932	11.236	0.307	51.86%	75.72%
Linear Regression	6.70	15.43	0.014	34.97%	64.05%

Linear Regression: 데이터를 1%밖에 설명하지 못함

그러나 RF와 SVM의 성능도 높지 않아 성능을 개선해 비교

추가 데이터 전처리

기존

벌금형만 있는 경우
sentence_months = 1로 처리

⇓

벌금 100만원과 벌금 1000만원이
같은 형량으로 취급

개선

벌금액을 노역장 유치 기준을
참고하여 **개월 수로 환산**

```
1일 = 10만원
30일 = 1개월
```

벌금형 사건 내부의 차이를 반영

예: 500만원 → 1.67개월, 1000만원 → 3.33개월

모델 최적화

GridSearchCV 확장

모델	기존 탐색 규모	확장 탐색 규모
SVM	80 후보 (400 fits)	175 후보 (875 fits)
Random Forest	108 후보 (540 fits)	324 후보 (1620 fits)

Log Transformation

큰 형량 값의 영향력을 줄이고,
모델이 전체적으로 안정적인 예측을 하도록 하기 위해
target인 sentence_months에 로그 변환을 적용

y = log1p(sentence_months)

추가 실험 진행

	MAE	RMSE	R^2	Accuracy Toler : 3	Accuracy Toler : 6
Random Forest	4.916	10.805	0.359	48.05%	77.80%
Random Forest ver.2	4.749	10.861	0.338	49.70%	**79.03%**
SVM	4.932	11.236	0.307	51.86%	75.72%
SVM ver.2	**4.701**	**10.083**	**0.364**	**53.77%**	77.32%

추가 실험을 진행한 SVM이 전반적으로 가장 우수한 성능을 보임

성능 확인

Z	AA	AB	AC
actual_sentence_mo	predicted_sentence_	error_months	difference
18	14.26	3.74	-3.74
12	11.12	0.88	-0.88
18	13.76	4.24	-4.24
18	16.68	1.32	-1.32
12	8.28	3.72	-3.72
1.67	1.66	0.01	-0.01

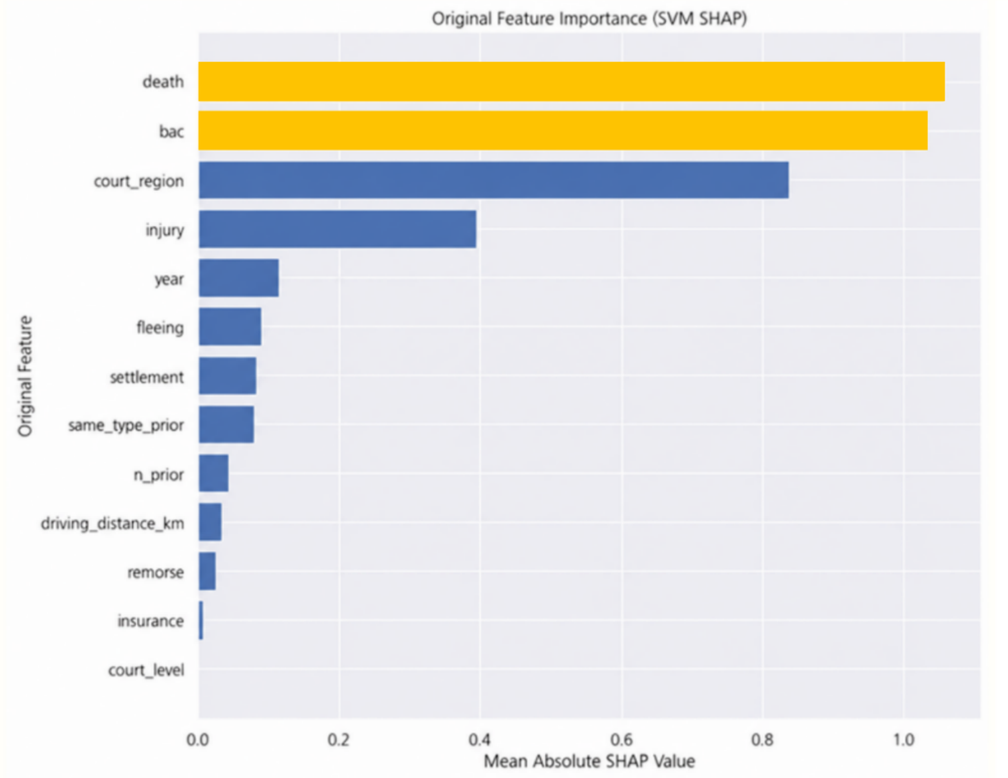
실제 모델 예측 결과 파일 예시

실제 형량과 예측 형량 간 차이가 크지 않게 나타남을 확인

Phase 3. Result

형량 영향 요소 1

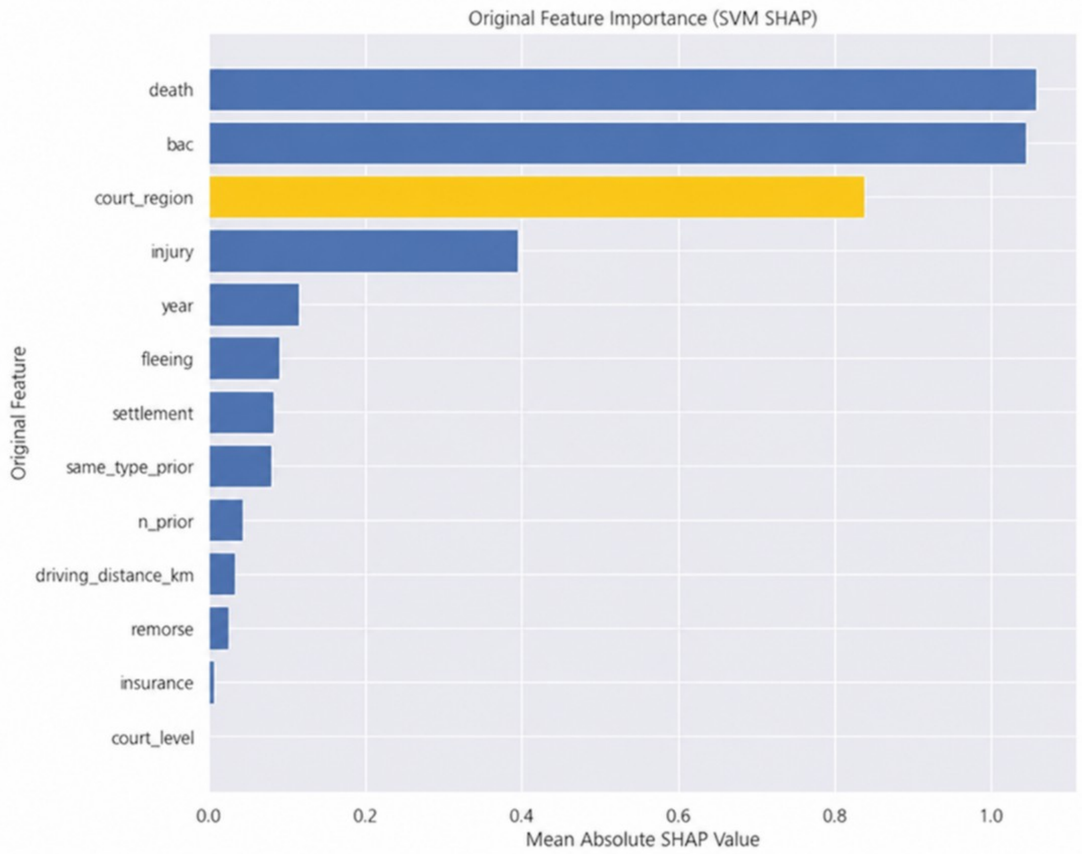
사망 여부 & 혈중 알코올 농도



실제 법원 양형 판결의 주된 변수로,
팀의 기존 예상대로
법적 상식을 왜곡없이 잘 학습하였음을 시사

형량 영향 요소 2

관할지

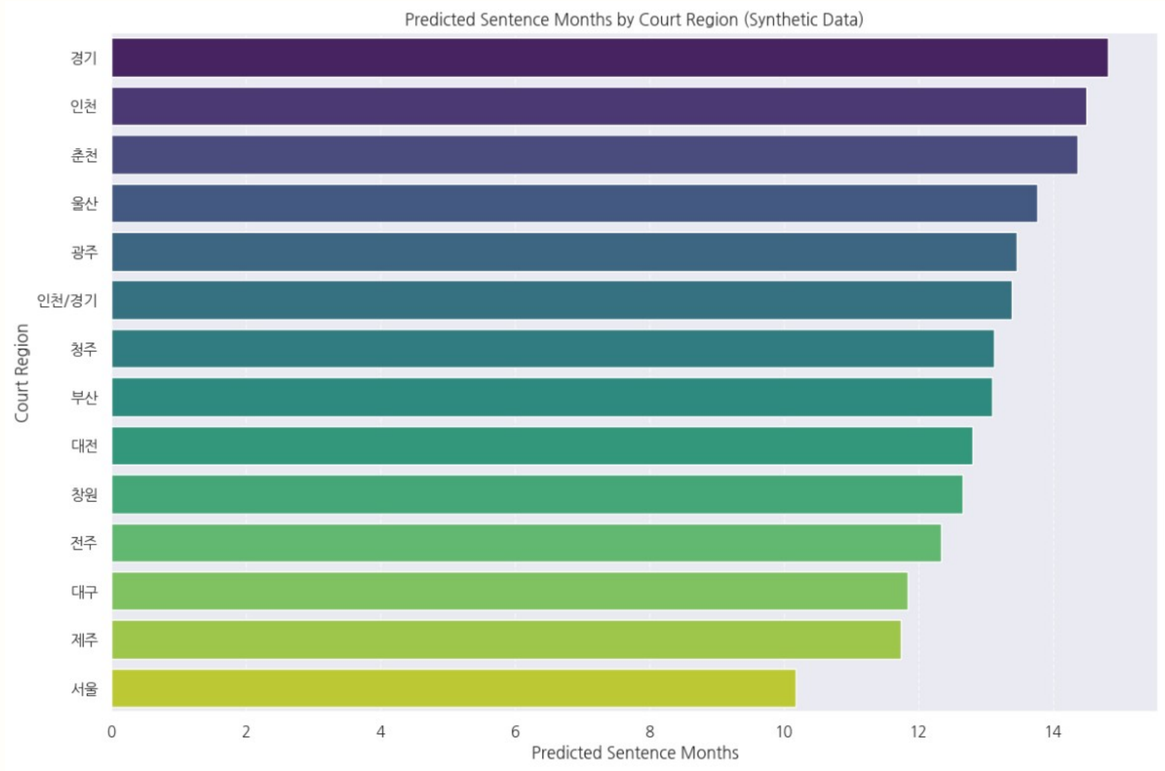


도주 여부, 전과 횟수보다
압도적인 feature importance

지역별 양형 불균형의 근거

형량 영향 요소 2

관할지



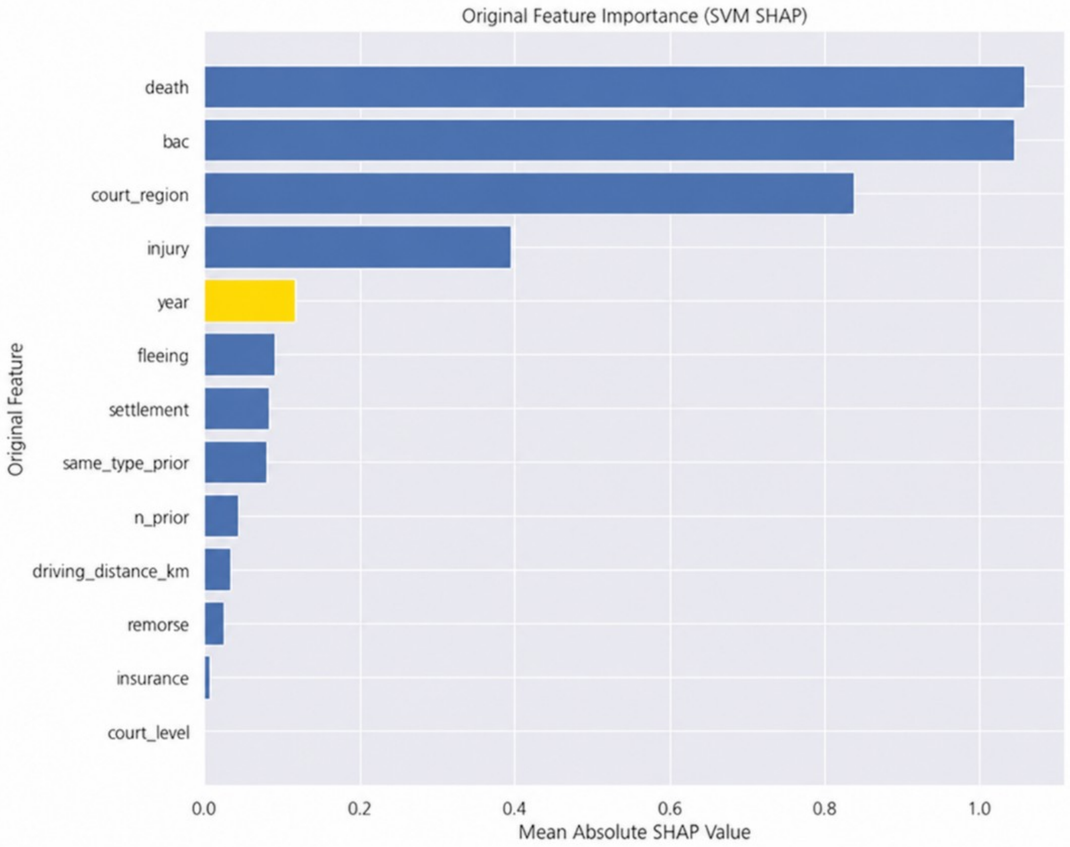
경기·인천이 가장 높고, 서울이 가장 낮다

동일 조건 가상 데이터 기준, 경기(~15개월)와 서울(~10개월) 간 약 5개월 차이 발생

같은 사건도 어느 법원에서 재판받느냐에 따라 형량이 달라질 수 있음을 모델이 포착

형량 영향 요소 3

시간



시간의 흐름에 따라 형량이 달라짐

윤창호법 및 여러 법 개정이
양형의 기준선을 매년 높이고 있음

모델 활용 방안

BAC Result < .15 or No Test Result	*No Prior Offense*	*One Prior Offense*	*Two Prior Offenses*
Mandatory Minimum/ Maximum Jail Time	24 Consecutive Hours/364 Days	30/364 Days	90/364 Days
Each Passenger Under Age 16, Mandatory Jail	Additional 24 Hours Consecutive	Additional 5 Days Consecutive	Additional 10 Days Consecutive
EHM or Jail Alternative	15 Days in Lieu of Jail	60 Days Mandatory	120 Days Mandatory/8 Days Jail Min.
Alternative to Mandatory Jail + EHM	N/A	180 Days EHM or 120 days of 24/7 sobriety program monitoring	360 Days EHM or 360 days of 24/7 sobriety program monitoring
Mandatory Minimum/ Maximum Fine***	$990.50/$5,000	$1,245.50/$5,000	$2,095.50/$5,000
If Passenger Under Age 16, Minimum/ Maximum Range***	$1,000/$1,000-$5,000 + assessments	$1,000/$2,000-$5,000 + assessments	$1,000/$3,000-$10,000 + assessments
Driver's License**	90-Day Suspension	2-Year Revocation[5]	3-Year Revocation
Each Passenger Under Age 16, II Device	Additional 12 Months	Additional 12 Months	Additional 12 Months
24/7 Sobriety Program	If available	If available	If available
Alcohol/Drug Ed./Victim Impact or Treatment	As Ordered	As Ordered	As Ordered
Expanded Substance Use Disorder Assessment/Treatment	N/A	Mandatory/treatment if appropriate	Mandatory/treatment if appropriate
II Device[1]	DOL imposed in all cases.		
BAC Result ≥ .15 or Test Refusal	***No Prior Offense***	***One Prior Offense***	***Two Prior Offenses***
Mandatory Minimum/ Maximum Jail Time	48 Consecutive Hours/364 Days	45/364 Days	120/364 Days
Each Passenger Under Age 16, Mandatory Jail	Additional 24 Hours Consecutive	Additional 5 Days Consecutive	Additional 10 Days Consecutive
EHM or Jail Alternative	30 Days in Lieu of Jail	90 Days Mandatory	150 Days Mandatory/10 Days Jail Min.

Washington State Courts - DUI Sentencing Grid

미국의 양형 기준표

정량적 수치 기준으로 세분화된 형량

형량 예측 용이

혈중 알코올 농도

전과 횟수

모델 활용 방안

구분		감경요소	가중요소
특별양형인자	행위	· 범행동기에 특히 참작할 사유가 있는 경우 · 운전으로 인한 도로교통상의 위험이 매우 낮은 경우	· 운전으로 인한 도로교통상의 위험이 매우 높은 경우 · 공무수행에 상당한 지장을 초래한 경우(5유형)
	행위자/기타	· 청각 및 언어 장애인 · 심신미약(본인 책임 없음) · 자수	· 동종 누범
일반양형인자	행위	· 생계형 범죄(1유형)	
	행위자/기타	· 진지한 반성 · 형사처벌 전력 없음	· 범행 후 증거은폐 또는 은폐 시도 · 이종 누범, 누범에 해당하지 않는 동종 전과(집행 종료 또는 판결 확정 후 10년 미만)

대한민국 법원 양형위원회 / 교통범죄 양형기준

한국의 양형 기준표

정량적 수치 & 정성적 인자 기준으로 선고

형량 예측 난해

모델 도입을 통해
일관된 형량 예측 표준 형성 가능

한계점

합의의 질적 과정

2021도11126, 2021도10444

- 피해자가 경제적 곤궁으로 합의금을 받고, 처벌 불원서를 제출한 경우

- 피해자 압박 및 회유로 합의한 경우

- 선고 직전 기습 공탁

반성의 진정성

2025도10910

- 단순 반성문 제출을 넘어 구체적 재범 방지 행동을 통해 반성의 진정성 인정

법정 태도

2021도11653

- 법정에서 불량한 태도 혹은 반성하는 태도를 보임에 따라 형량 판결에 변수가 될 수 있음

향후 연구 계획



판결문 데이터 규모 확대



NLP 기반
판결문 원문 분석



XGBoost·LightGBM 등
고성능 모델 도입



지역별 양형 편차 분석을 통한
사법 공정성 연구

Thank You